

Rahul Rawat

Masterarbeit Data Science und Machine Learning im Spritzguss

P E R S Ö N L I C H E D A T E N

Adresse	C2 16, 68159 Mannheim, Deutschland
Telefon	015563603340
E-Mail	rahulrawat2r@gmail.com
LinkedIn	linkedin.com/in/rahulrawat2r
GitHub	github.com/rahulrawat20022002
Portfolio	rah-portfolio.pages.dev
Geburtsdatum	20 February 2002
Nationalität	Indisch, Studentenvisum mit gültiger Arbeitserlaubnis
Verfügbarkeit	Werkstudent 20 Stunden pro Woche sofort, Vollzeit ab April 2027

P R O F I L

Masterstudent der Data Science and Analytics an der SRH Heidelberg in Mannheim, mit Praxis im Aufbau produktionsnaher Machine Learning Pipelines auf realen Sensor und Prozessdaten. Bei eRay GmbH habe ich eine rekursive Zeitreihen Pipeline geliefert, die vier Wasserqualitätsindikatoren prognostiziert und sechs Modelle direkt vergleicht, mit CatBoost Multi Quantil Regression fuer 80 Prozent Vorhersageintervalle. Sicher in Python, scikit learn, CatBoost, LightGBM, XGBoost und Prophet, mit klarem Blick fuer Datenqualitaet, Anti Leakage und robuste Modellbewertung.

B E R U F S E R F A H R U N G

Okt 2025 bis Mrz 2026
Heidelberg

eRay GmbH
Data Scientist

- Entwickelte eine end to end rekursive Zeitreihen Pipeline zur Prognose von Chlorophyll a, Trübung, pH Wert und gelöstem Sauerstoff für einen deutschen See, umgesetzt als sechsmonatige Zusammenarbeit mit der SRH Hochschule Heidelberg.
- Vergleich sechs Modelle direkt, Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet, und nutzte CatBoost Multi Quantil Regression, um asymmetrische 80 Prozent Vorhersageintervalle für die Entscheidungsunterstützung unter Unsicherheit zu liefern.
- Erzwang strenge Anti Leakage Regeln in der gesamten Pipeline und legte die ehrliche Erkenntnis offen, dass pH Wert und gelöster Sauerstoff physikalisch vorhersagbar sind, während Chlorophyll a und Trübung ohne optische Live Sensorik nicht seriös prognostizierbar sind.
- Rekonstruierte fehlende Winter Messwerte mit MICE Imputation und entwickelte einen synthetischen Winter Decay Prognose Rahmen, damit baumbasierte Modelle während der rekursiven Vorhersage nicht flach werden.
- Umschloss die gesamte Pipeline mit einem Orchestrator, der Gate Checks sowie Geschwindigkeits und ökologische Grenzen prüft und bei fehlgeschlagener Imputation stoppt, statt schlechte Daten weiterfließen zu lassen.

Technologies: *Python, CatBoost, Prophet, scikit learn, MICE*

P E R S Ö N L I C H E P R O J E K T E

2025

CreditIQ: Fairness by Design Credit Scoring

- Hob den Disparate Impact Wert des Modells von einem durchgefallenen 0,79 auf einen konformen 0,88, messbar am 80 Prozent Fairness Grenzwert nach EU AI Act und AGG, umgesetzt mit AIF360 Mitigation und Schwellenwertkalibrierung auf einem realen Kreditdatensatz.
- Deckte eine versteckte intersektionale Verzerrung auf, bei der jüngere Frauen selbst nach der Korrektur der einachsigen Altersverzerrung weiterhin benachteiligt waren, messbar über SHAP getriebene Subgruppenanalyse, und entwarf eine vierfeldrige Alter und Geschlecht Schwellenwertmatrix, um dies zu korrigieren ohne in umgekehrte Diskriminierung zu kippen.
- Senkte die False Negative Rate von 44 Prozent auf 16,7 Prozent bei stabiler Genauigkeit von 75 Prozent, messbar am Held Out Test Split, indem der Fairness Accuracy Trade off als bewusste und regulatorisch belastbare Entscheidung dokumentiert wurde.
- Lieferte ein Streamlit Entscheidungsunterstützungs Tool aus, das Finanzverantwortlichen eine Empfehlung plus eine in einfacher Sprache generierte LLM Erklärung gibt, messbar gegen die Human in the Loop Anforderungen aus GDPR Artikel 22 und EU AI Act Artikel 14, und stützte die Pipeline durch Unit Tests mit 100 Prozent Branch Coverage sowie eine vollständige regulatorische Dokumentation ab.

Technologies: *Python, scikit learn, AIF360, SHAP, Streamlit*

2025

Echtzeit Flugverfolgungs Pipeline

- Sammelte alle 30 Sekunden Live Flugpositionen von der OpenSky Network API und reicherte sie über vier Quellen aus Flughafen, Flugzeug und Wetterdaten an, messbar an einer sauberen Join Tabelle mit über 128 tausend Datensätzen, umgesetzt mit Python Collectors und PySpark Cleaning auf Google Cloud.
- Formte die Rohdaten mit dbt in analysebereite Tabellen und berechnete dabei den nächstgelegenen Flughafen jedes Flugzeugs, messbar an konsistenten Labels über den gesamten Zeitraum, gestützt auf PySpark für den Rechenaufwand und dbt für die Modellierungsschicht.
- Orchestrierte das Gesamtsystem mit Apache Airflow, so dass sich Batch und Echtzeit Schichten automatisch alle **15 Minuten** aktualisieren, messbar an unbeaufsichtigten DAG Läufen auf GCS Speicher und Dataproc Compute.
- Visualisierte Erkenntnisse in einem Tableau Workbook mit Python Statistik über TabPy, messbar an der Erkenntnis, dass der Luftverkehr bei starkem Regen um Faktor 4,4 einbricht und sich um Drehkreuze wie Frankfurt und München bündelt, gestützt auf dbt Aggregate als Feed.

Technologies: *Python, PySpark, BigQuery, dbt, Apache Airflow, GCP Dataproc und GCS, Tableau mit TabPy*

A U S B I L D U N G

Apr 2025 bis
heute

Heidelberg

M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9

2019 to 2023

Greater Noida,
India

Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10

F O R S C H U N G U N D A B S C H L U S S A R B E I T

2022 to 2023

Greater Noida,
India

Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE style paper

- Entwickelte eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren auf einem klinischen Datensatz von **768 Patientinnen** und Patienten, gestützt auf 10 fache Kreuzvalidierung und pro Modell erstellte Konfusionsmatrizen, damit der Modellvergleich prüfbar bleibt.
- Erkannte biologisch unmögliche Nullwerte, die die Originalautoren übersehen hatten, und entfernte diese über IQR basierte Ausreißerbehandlung und saubere Imputation, um die Datenintegrität vor jedem Modelltraining wiederherzustellen.
- Wählte ROC AUC statt Genauigkeit als Leitmetrik für einen unausgeglichene Datensatz mit 65 zu 35 Verteilung, um eine trügerisch schöne Genauigkeit zu vermeiden, die reale Fehler in der Minderheitsklasse verdeckt hätte.
- Verfasse die Ergebnisse als IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie, in Substanz veröffentlichungsreif.

Technologies: *Python, scikit learn, Pandas, Seaborn*

Z E R T I F I K A T E

- NVIDIA: Building LLM Applications With Prompt Engineering, ausgestellt im November 2025.
- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- Google Data Analytics: Foundations, Data, Data, Everywhere, ausgestellt im April 2025 auf Coursera.

A U S Z E I C H N U N G E N

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

S P R A C H E N

Englisch	Fließend, schriftlich und mündlich
Deutsch	B1 laufend Richtung B2
Hindi	Muttersprache

Mannheim, 26 July 2026

Rahul Rawat