

Rahul Rawat

Masterarbeit im Bereich Process Mining

P E R S Ö N L I C H E D A T E N

Adresse	C2 16, 68159 Mannheim, Deutschland
Telefon	015563603340
E-Mail	rahulrawat2r@gmail.com
LinkedIn	linkedin.com/in/rahulrawat2r
GitHub	github.com/rahulrawat20022002
Portfolio	rah-portfolio.pages.dev
Geburtsdatum	20 February 2002
Nationalität	Indisch, Studentenvisum mit gültiger Arbeitserlaubnis
Verfügbarkeit	Werkstudent 20 Stunden pro Woche sofort, Vollzeit ab April 2027

P R O F I L

Masterstudent der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim und praktischer Erfahrung im Aufbau end to end Datenpipelines, Machine Learning auf Prozessdaten und BI Reporting. Ich habe eine vollstaendig automatisierte Bronze Silver Gold Medallion Pipeline in BigQuery mit einem leakage freien BigQuery ML Klassifikator und fuenfseitigem Looker Studio Dashboard umgesetzt, eine Echtzeit Cloud Pipeline mit PySpark, dbt und Apache Airflow ueber mehr als 128 tausend Datensatze betrieben und ein interaktives Tableau Dashboard mit dynamischen Set Actions und parametergesteuerten Analytiken ausgeliefert. Sicher in Python, SQL und mit analytischem und konzeptionellem Blick fuer betriebliche Prozessdaten, bin ich die richtige Verstaerkung fuer die Masterarbeit im Process Mining bei ROSEN in Lingen.

B E R U F S E R F A H R U N G

Okt 2025 bis Mrz 2026
Heidelberg

eRay GmbH
Data Scientist

- Entwickelte eine end to end rekursive Zeitreihen Pipeline zur Prognose von Chlorophyll a, Trübung, pH Wert und gelöstem Sauerstoff für einen deutschen See, umgesetzt als sechsmonatige Zusammenarbeit mit der SRH Hochschule Heidelberg.
- Vergleich sechs Modelle direkt, Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet, und nutzte CatBoost Multi Quantil Regression, um asymmetrische 80 Prozent Vorhersageintervalle für die Entscheidungsunterstützung unter Unsicherheit zu liefern.
- Erzwang strenge Anti Leakage Regeln in der gesamten Pipeline und legte die ehrliche Erkenntnis offen, dass pH Wert und gelöster Sauerstoff physikalisch vorhersagbar sind, während Chlorophyll a und Trübung ohne optische Live Sensorik nicht seriös prognostizierbar sind.
- Rekonstruierte fehlende Winter Messwerte mit MICE Imputation und entwickelte einen synthetischen Winter Decay Prognose Rahmen, damit baumbasierte Modelle während der rekursiven Vorhersage nicht flach werden.
- Umschloss die gesamte Pipeline mit einem Orchestrator, der Gate Checks sowie Geschwindigkeits und ökologische Grenzen prüft und bei fehlgeschlagener Imputation stoppt, statt schlechte Daten weiterfließen zu lassen.

Technologies: *Python, CatBoost, Prophet, scikit learn, MICE*

P E R S Ö N L I C H E P R O J E K T E

2025

Movie Analytics und ML Pipeline auf GCP

- Baute eine end to end Batch Pipeline, die Filmdaten aus einer öffentlichen API in einen GCS Data Lake zieht und sie über eine Bronze Silver Gold Medallion Architektur in BigQuery verarbeitet, messbar an einem vollständig automatisierten Cloud Scheduler Trigger ohne manuellen Eingriff, umgesetzt mit Cloud Run als Compute Layer.
- Modellerte die Silver Schicht für verlässliche Analytik über Schema Enforcement, sicheres Type Casting, Deduplikation per Window Functions und Genre Normalisierung in ein relationales Modell, messbar an der referenziellen Integrität in allen Gold Tabellen.
- Trainierte einen BigQuery ML Klassifikator, der vor Kinostart vorhersagt, ob ein Film ein Hit wird, messbar an einer leakage freien Evaluation, indem Merkmale bewusst in zwei Tabellen aufgeteilt wurden, so dass nur Pre Release Signale ins Modell fließen.
- Baute Gold Aggregate und ein fünfseitiges Looker Studio Dashboard, das konkrete Business Fragen zu Genre ROI, Wachstum fremdsprachiger Filme und Release Saison Timing beantwortet, messbar gegen die ML Early Warning Sicht, und sicherte das System mit einem Least Privilege Service Account und Secret Manager ab.

Technologies: *GCP BigQuery, Cloud Run, GCS, Cloud Scheduler, BigQuery ML, Python, SQL, Looker Studio*

2025

Fast Food Nährwert Analyzer und Meal Simulator

- Baute einen dynamischen Warenkorb in Tableau, messbar daran, dass Endnutzer Punkte im Scatter Plot auswählen und sofort Kalorien, Fett und Eiweiß eines simulierten Menüs summiert bekommen, umgesetzt mit Tableau Set Actions als Interaktionsschicht.
- Setzte parameter gesteuerte Analytik um, mit dynamischer Y Achse gekoppelt an einen Zielparameter für Muskelaufbau oder Gewichtsverlust, messbar am konsistenten Achsenwechsel ohne Dashboard Reload, gestützt auf ein CASE Statement über den Parameter.
- Formulierte komplexe IF THEN Calculated Fields für logische Gruppierung und eigene Flags wie ein Is It A Trap Flag für trügerisch fett und kalorienreiche Produkte, messbar über manuelle Stichproben gegen die Nährwertquelle.
- Entwarf ein zweistufiges Layout mit Executive Makro Sicht und granularer Food Finder Sicht in einer farbenblind sicheren Dark Mode Palette, messbar an einem Ziel geringerer Time to Insight für Nicht Techniker.

Technologies: *Tableau mit Set Actions, Parameter und Calculated Fields, Data Storytelling und UI oder UX*

Live: *public.tableau.com/shared/YC6Y4ZBM5*

2025

Echtzeit Flugverfolgungs Pipeline

- Sammelte alle 30 Sekunden Live Flugpositionen von der OpenSky Network API und reicherte sie über vier Quellen aus Flughafen, Flugzeug und Wetterdaten an, messbar an einer sauberen Join Tabelle mit über 128 tausend Datensätzen, umgesetzt mit Python Collectors und PySpark Cleaning auf Google Cloud.
- Formte die Rohdaten mit dbt in analysebereite Tabellen und berechnete dabei den nächstgelegenen Flughafen jedes Flugzeugs, messbar an konsistenten Labels über den gesamten Zeitraum, gestützt auf PySpark für den Rechenaufwand und dbt für die Modellierungsschicht.
- Orchestrierte das Gesamtsystem mit Apache Airflow, so dass sich Batch und Echtzeit Schichten automatisch alle **15 Minuten** aktualisieren, messbar an unbeaufsichtigten DAG Läufen auf GCS Speicher und Dataproc Compute.
- Visualisierte Erkenntnisse in einem Tableau Workbook mit Python Statistik über TabPy, messbar an der Erkenntnis, dass der Luftverkehr bei starkem Regen um Faktor 4,4 einbricht und sich um Drehkreuze wie Frankfurt und München bündelt, gestützt auf dbt Aggregate als Feed.

Technologies: *Python, PySpark, BigQuery, dbt, Apache Airflow, GCP Dataproc und GCS, Tableau mit TabPy*

AUSBILDUNG

Apr 2025 bis
heute
Heidelberg

M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9

2019 to 2023
Greater Noida,
India

Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10

FORSCHUNG UND ABSCHLUSSARBEIT

2022 to 2023
Greater Noida,
India

Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE style paper

- Entwickelte eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren auf einem klinischen Datensatz von **768 Patientinnen** und Patienten, gestützt auf 10 fache Kreuzvalidierung und pro Modell erstellte Konfusionsmatrizen, damit der Modellvergleich prüfbar bleibt.
- Erkannte biologisch unmögliche Nullwerte, die die Originalautoren übersehen hatten, und entfernte diese über IQR basierte Ausreißerbehandlung und saubere Imputation, um die Datenintegrität vor jedem Modelltraining wiederherzustellen.
- Wählte ROC AUC statt Genauigkeit als Leitmetrik für einen unausgeglichene Datensatz mit 65 zu 35 Verteilung, um eine trügerisch schöne Genauigkeit zu vermeiden, die reale Fehler in der Minderheitsklasse verdeckt hätte.
- Verfasste die Ergebnisse als IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie, in Substanz veröffentlichungsreif.

Technologies: *Python, scikit learn, Pandas, Seaborn*

ZERTIFIKATE

- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- SAS Certified Specialist: Visual Business Analytics Using SAS Viya, ausgestellt im Mai 2025.
- Google Data Analytics: Foundations, Data, Data, Everywhere, ausgestellt im April 2025 auf Coursera.

AUSZEICHNUNGEN

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

SPRACHEN

Englisch Fließend, schriftlich und mündlich
Deutsch B1 laufend Richtung B2
Hindi Muttersprache

Mannheim, 26 July 2026

Rahul Rawat