

# Rahul Rawat

Werkstudent Data Science und KI Tool Entwicklung fuer Qualitaetsanalyse

---

## PERSÖNLICHE DATEN

---

**Adresse:** C2 16, 68159 Mannheim, Deutschland

**Telefon:** 015563603340

**E-Mail:** rahulrawat2r@gmail.com

**LinkedIn:** linkedin.com/in/rahulrawat2r

**GitHub:** github.com/rahulrawat20022002

**Portfolio:** rah-portfolio.pages.dev

**Geburtsdatum:** 20 February 2002

**Nationalität:** Indisch, Studentenvisum mit gültiger Arbeitserlaubnis

**Verfügbarkeit:** Werkstudent 20 Stunden pro Woche sofort, Vollzeit ab April 2027

## PROFIL

---

Masterstudent der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim und praktischer Erfahrung im Aufbau von Machine Learning Pipelines, LLM Werkzeugen und Qualitaets naher Analyse. Ich habe bei eRay GmbH eine end to end rekursive Zeitreihen Pipeline mit CatBoost MultiQuantile und **80 Prozent** Vorhersageintervallen fuer 4 Umweltindikatoren geliefert und ein Multi Agent RAG System mit LangGraph, Ollama Mistral **7B** und Qwen**2.5 14B** sowie einer belastbaren LLM as Judge Evaluation ueber **5 Dimensionen** aufgebaut. Sicher in Python, SQL, scikit-learn, LangGraph, Prophet, CatBoost, GCP und AWS.

## FÄHIGKEITEN

---

Python, SQL, PySpark, BigQuery, Databricks, Delta Lake, Power BI, Tableau, Looker Studio, LangChain, LangGraph, Ollama, CatBoost, LightGBM, XGBoost, Prophet, MICE, scikit-learn, PyTorch, dbt, Apache Airflow, GCP, AWS, Docker, Git, React, Playwright

## BERUFSERFAHRUNG

---

### eRay GmbH

*Data Scientist · Heidelberg · Okt 2025 bis Mrz 2026*

- In einer **6 monatigen** Zusammenarbeit zwischen eRay GmbH und SRH Hochschule Heidelberg zur Prognose der Seewasserqualität über **4 Ziel** Indikatoren Chlorophyll a, Trübung, pH und gelösten Sauerstoff wurde eine end to end rekursive Zeitreihen Pipeline über einen **40 Feature** Raum mit einem Ziel Lag Set lag\_1h, lag\_24h, lag\_3d, lag\_7d, lag\_roll\_mean\_24h und lag\_roll\_std\_24h aufgebaut.
- Es wurden **6 Kandidaten** direkt verglichen Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet mit strikten Tree Einschränkungen max\_depth 4 und learning\_rate **0.05**, die Entscheidung fiel auf CatBoost MultiQuantile bei alpha **0.05**, **0.5** und **0.85**, was asymmetrische **80 Prozent** Vorhersageintervalle lieferte, die den 0 Boden umarmen und die oberen **15 Prozent** der Sommer Ghost Spikes abschneiden.
- Die September Evaluation wurde belastbar gemacht mit einem **3 Pass** Outlier System pH verengt von **0 bis 14** auf **7.0 bis 9.0**, Oct und Nov Caps von **15.0** bei Chlorophyll a und **50.0** bei Trübung, ein rollender z-score bei  $z > 2.5$  über **48 Stunden**, und 5 spärliche Sensoren plus 3 zeitgleiche Proxies phycocyanin\_abs, phycocyanin\_abs\_comp und toc wurden ausgeschlossen, was die ehrliche R quadrat Aufteilung von **0.86** bei gelöstem Sauerstoff und **0.81** bei pH offenlegte.
- Oct und Nov Lücken wurden mit IterativeImputer MICE rekonstruiert, eine vollständige Memory Buffer Neuberechnung über alle 6 Lag Features durchgeführt, ein synthetisches Winter Canvas mit 4 Grad Celsius Boden und **0.4** Grad diurnaler Amplitude generiert und das Ganze in einen Orchestrator mit Gate Checks, ökologischen Clips gelöster Sauerstoff **4.0 bis 18.0** und pH **6.0 bis 9.0** und einem **0.003** pH pro Stunde Velocity Clamp eingebettet.

**Technologies:** Python, CatBoost, Prophet, scikit learn, MICE

## SS Engineers and Contractors

Junior Associate Software Developer · India · Aug 2023 bis Aug 2024

- Da SS Engineers and Contractors interne Data Dashboards, Analytics Plattformen und Mitarbeiter Portale betreibt, die unternehmensweit genutzt werden, mit dem Auftrag die Frontend Features zu bauen und zu pflegen, auf die die Teams im Alltag angewiesen sind, wurden React UI Komponenten in allen drei internen Produkten beigetragen, die während des gesamten Jahres in der Rolle im täglichen Einsatz der internen Teams blieben.
- Bei einem Kunden, dessen Legacy AngularJS Anwendung in einem bestehenden Module Federation Setup neben neueren React Micro Frontends laufen sollte, mit dem Auftrag die Screens des Kunden zu portieren ohne das laufende Produkt zu brechen, wurden rund **8 Routen** von AngularJS auf React innerhalb der Module Federation Shell portiert, ausgeliefert über **4 Monate** in schrittweisen Releases und ohne Produktionsausfälle während des Rollouts eingespielt.

**Technologies:** React, module federation, Playwright, AngularJS, HTML5, CSS3

## SS Engineers and Contractors

Front End Developer Intern · India · Feb 2023 bis Juli 2023

- Während eines sechsmonatigen Praktikums bei SS Engineers and Contractors, mit dem Auftrag die Codebasis kennenzulernen und dann unter Senior Review kleinere UI Arbeiten in den internen Data Dashboards und Mitarbeiter Portalen zu übernehmen, wurde eng mit Senior Entwicklern durch die Codebasis gegangen und anschließend wurden fokussierte UI Komponenten wie Charts, Filter und Profilseiten geliefert, jede iterativ auf Basis von Code Review Feedback verbessert bis sie freigegeben war.

**Technologies:** React, HTML5, CSS3, Git, code review workflow

## AUSBILDUNG

### M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9 · Heidelberg · Apr 2025 bis heute

### Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10 · Greater Noida, India · 2019 to 2023

## PERSÖNLICHE PROJEKTE

### Multi-Agent RAG mit LLM-as-Judge und mehrsprachiger EN und DE Unterstützung

2025

- Für ein rein englisches Hybrid RAG Policy Analysesystem mit BM25 und dichter Vektorsuche über einen **14 Dokumente** Policy Korpus, das deutschsprachige Nutzer nicht bedienen konnte, mit dem Auftrag mehrsprachige Unterstützung ohne Korpus Duplizierung hinzuzufügen, wurden Embeddings und Retrieval auf einen paraphrase multilingual MiniLM L12 v2 gemeinsamen Vektorraum migriert, sodass eine deutsche Anfrage englische Quellen abrufen und end to end auf Deutsch beantwortet wird.
- Da jeder Agent im Graph erneut Spracherkennung ausführte und inkonsistente Ausgabesprachen produzierte, mit dem Auftrag eine zentrale Wahrheitsquelle zu schaffen, wurde ein LanguageAgent gebaut, der geseedete Spracherkennung mit einem Confidence Floor zentralisiert, die Ausgabesprache Direktive an jeden nachgelagerten Agent weiterreicht und Preprocessing an sprachpassende spaCy Pipelines mit einem leeren Multilingual Fallback routet und die Sprache pro Chunk protokolliert, sodass Retrieval und Evaluation nach Sprache geschnitten werden können.
- Um Antwortqualität ohne manuelle Bewertung zu messen, wurde ein LLM as Judge JudgeAgent implementiert, der Antworten mit **1 bis 5** auf **5 Dimensionen** (Groundedness, Relevance, Completeness, Citation Quality, Language Quality) im JSON Modus bei Temperatur 0 bewertet, und Self Preference Bias wurde eliminiert, indem der Judge auf einem anderen lokalen Modell Qwen2.5 **14B** lief als der Generator Mistral **7B**, mit einem self\_judged Flag in jedem Report und einer harten Fehlerbehandlung bei fehlendem Judge Modell, damit ein stiller Rückfall auf Self Judging nicht unbemerkt regressieren kann.

**Technologies:** Python, LangGraph Multi Agent, Ollama mit Mistral 7B und Qwen2.5 14B, Pinecone, paraphrase multilingual MiniLM L12 v2, spaCy, BM25

## FORSCHUNG UND ABSCHLUSSARBEIT

---

### Bachelorarbeit: Diabetesvorhersage mit Machine Learning

*GL Bajaj Institute of Technology and Management, IEEE style paper · Greater Noida, India · 2022 to 2023*

- Für eine Bachelorarbeit zur Diabetesvorhersage auf einem kleinen klinischen Datensatz von **768 Patientinnen** und Patienten, mit dem Auftrag einen belastbaren Modellvergleich zu liefern, den die Prüfer nachprüfen können, wurde eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren, **10 facher** Kreuzvalidierung und pro Modell erstellten Konfusionsmatrizen aufgebaut, was einen Modellvergleich ergab, der in der Verteidigung standhielt.
- Nach dem Erkennen biologisch unmöglicher Nullwerte in den Quelldaten, die die Originalautoren übersehen hatten, mit dem Auftrag die Datenintegrität vor jedem Modelltraining wiederherzustellen, wurde eine IQR basierte Ausreißerbehandlung und saubere Imputation angewandt, was den Datensatz von still fehlerhaft zu einer sauberen Trainingsgrundlage für jedes nachgelagerte Modell brachte.
- Bei einer 65 zu **35 Klassen**ungleichgewicht Verteilung, die Genauigkeit zu einer trügerisch schönen Leitmetrik gemacht hätte, mit dem Auftrag eine Bewertung zu wählen, die Fehler in der Minderheitsklasse nicht verdeckt, wurde die Leitmetrik von Genauigkeit auf ROC AUC umgestellt, was die realen Fehlermuster offenlegte, die die Genauigkeitszahl maskiert hatte und der Arbeit einen ehrlichen Leistungsvergleich gab.
- Da die Ergebnisse in der Substanz veröffentlichungsreif und nicht nur abgabefähig sein sollten, mit dem Auftrag sie formal aufzuschreiben, wurde ein IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie verfasst, das der Betreuer als in der Substanz veröffentlichungsreif akzeptierte.

**Technologies:** *Python, scikit learn, Pandas, Seaborn*

## ZERTIFIKATE

---

- NVIDIA: Building LLM Applications With Prompt Engineering, ausgestellt im November 2025.
- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- Google Data Analytics: Foundations, Data, Data, Everywhere, ausgestellt im April 2025 auf Coursera.

## AUSZEICHNUNGEN

---

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

## SPRACHEN

---

**Englisch:** Fließend, schriftlich und mündlich

**Deutsch:** B1 laufend Richtung B2

**Hindi:** Muttersprache