

Rahul Rawat

Masterstudent Data Science and Analytics | Strukturierte Experimente und Parameteroptimierung | Python + Datenanalyse

Mannheim, Deutschland · 015563603340 · rahulrawat2r@gmail.com

rah-portfolio.pages.dev · github.com/rahulrawat20022002 · linkedin.com/in/rahulrawat2r

Immatrikuliert bis April 2027 · Sofort verfügbar · Studentenvisum mit Arbeitserlaubnis

PROFIL

Masterstudent der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim mit einem quantitativen, datengetriebenen Hintergrund statt einer Materialwissenschaft oder additiven Fertigung Ausbildung. Ich bringe strukturiertes Experimentieren und Parameteroptimierung aus eigenen Machine Learning Projekten mit, in denen ich systematisch verschiedene Modellkonfigurationen verglichen, Schwellenwerte kalibriert und Ergebnisse sauber dokumentiert habe. Sicher in Python, in der statistischen Auswertung von Messreihen und in einer selbstständigen, strukturierten Arbeitsweise.

FÄHIGKEITEN

KI und Agenten	LangGraph, RAG, LLM as Judge, Prompt Engineering, Ollama, spaCy, BM25
Daten und ML	Python, SQL, PySpark, scikit learn, CatBoost, XGBoost, LightGBM, Prophet, MICE
Cloud und Orchestrierung	GCP, BigQuery, Cloud Run, AWS, Docker, Apache Airflow, dbt, Git
Dashboards	Tableau, Looker Studio, Streamlit, Power BI
Web	React, module federation, Playwright, HTML5, CSS3

BERUFSERFAHRUNG

eRay GmbH

Data Scientist · Heidelberg · Okt 2025 bis Mrz 2026

- In einer **6 monatigen** Zusammenarbeit zwischen eRay GmbH und SRH Hochschule Heidelberg zur Prognose der Seewasserqualität über **4 Ziel** Indikatoren Chlorophyll a, Trübung, pH und gelösten Sauerstoff wurde eine end to end rekursive Zeitreihen Pipeline über einen **40 Feature** Raum mit einem Ziel Lag Set lag_1h, lag_24h, lag_3d, lag_7d, lag_roll_mean_24h und lag_roll_std_24h aufgebaut.
- Es wurden **6 Kandidaten** direkt verglichen Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet mit strikten Tree Einschränkungen max_depth 4 und learning_rate **0.05**, die Entscheidung fiel auf CatBoost MultiQuantile bei alpha **0.05**, **0.5** und **0.85**, was asymmetrische **80 Prozent** Vorhersageintervalle lieferte, die den 0 Boden umarmen und die oberen **15 Prozent** der Sommer Ghost Spikes abschneiden.
- Die September Evaluation wurde belastbar gemacht mit einem **3 Pass** Outlier System pH verengt von **0 bis 14** auf **7.0 bis 9.0**, Oct und Nov Caps von **15.0** bei Chlorophyll a und **50.0** bei Trübung, ein rollender z-score bei $z > 2.5$ über **48 Stunden**, und 5 spärliche Sensoren plus 3 zeitgleiche Proxies phycocyanin_abs, phycocyanin_abs_comp und toc wurden ausgeschlossen, was die ehrliche R quadrat Aufteilung von **0.86** bei gelöstem Sauerstoff und **0.81** bei pH offenlegte.

Technologies: Python, CatBoost, Prophet, scikit learn, MICE

AUSBILDUNG

M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9 · Heidelberg · Apr 2025 bis heute

Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10 · Greater Noida, India · 2019 to 2023

PERSÖNLICHE PROJEKTE

Wirtschaftliche Analyse globaler Klimaereignisse

2025

- Für ein Data Science Projekt, das rohe globale Klimaereignis Daten in Entscheidungsunterstützung für Ressourcenallokation und Risikobewertung überführen sollte, mit dem Auftrag die gesamte Analyse Pipeline zu bauen, wurde ein end to end Projekt von der Ingestion bis zum Stakeholder Report umgesetzt, geliefert als reproduzierbare Pipeline von der Roh CSV bis zur management fähigen Ausgabe.
- Da die Rohdaten Ausreißer, fehlende Werte und inkonsistente Skalen enthielten, die jedes nachgelagerte Modell vergiften würden, mit dem Auftrag eine saubere Datenbasis zu schaffen, wurde fortgeschrittene Datenaufbereitung über Ausreißer, Imputation und Normalisierung durchgeführt, was stabile Modellleistung vor und nach dem Feature Scaling ergab.

Technologies: *Python mit Pandas und scikit learn, Random Forest, statistische Modellierung, Matplotlib und Seaborn*

FORSCHUNG UND ABSCHLUSSARBEIT

Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE style paper · Greater Noida, India · 2022 to 2023

- Für eine Bachelorarbeit zur Diabetesvorhersage auf einem kleinen klinischen Datensatz von **768 Patientinnen** und Patienten, mit dem Auftrag einen belastbaren Modellvergleich zu liefern, den die Prüfer nachprüfen können, wurde eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren, **10 facher** Kreuzvalidierung und pro Modell erstellten Konfusionsmatrizen aufgebaut, was einen Modellvergleich ergab, der in der Verteidigung standhielt.
- Nach dem Erkennen biologisch unmöglicher Nullwerte in den Quelldaten, die die Originalautoren übersehen hatten, mit dem Auftrag die Datenintegrität vor jedem Modelltraining wiederherzustellen, wurde eine IQR basierte Ausreißerbehandlung und saubere Imputation angewandt, was den Datensatz von still fehlerhaft zu einer sauberen Trainingsgrundlage für jedes nachgelagerte Modell brachte.
- Bei einer 65 zu **35 Klassenungleichgewicht** Verteilung, die Genauigkeit zu einer trügerisch schönen Leitmetrik gemacht hätte, mit dem Auftrag eine Bewertung zu wählen, die Fehler in der Minderheitsklasse nicht verdeckt, wurde die Leitmetrik von Genauigkeit auf ROC AUC umgestellt, was die realen Fehlermuster offenlegte, die die Genauigkeitszahl maskiert hatte und der Arbeit einen ehrlichen Leistungsvergleich gab.
- Da die Ergebnisse in der Substanz veröffentlichungsreif und nicht nur abgabefähig sein sollten, mit dem Auftrag sie formal aufzuschreiben, wurde ein IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie verfasst, das der Betreuer als in der Substanz veröffentlichungsreif akzeptierte.

Technologies: *Python, scikit learn, Pandas, Seaborn*

ZERTIFIKATE

- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- SAS Certified Specialist: Visual Business Analytics Using SAS Viya, ausgestellt im Mai 2025.
- Google Data Analytics: Foundations, Data, Data, Everywhere, ausgestellt im April 2025 auf Coursera.

AUSZEICHNUNGEN

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

SPRACHEN

Englisch: Fließend, schriftlich und mündlich

Deutsch: B1, laufend