

# Rahul Rawat

Masterstudent Data Science and Analytics | ML Pipelines fuer Produktionsdaten | Python + scikit learn + CatBoost

Mannheim, Deutschland · 015563603340 · rahulrawat2r@gmail.com

rah-portfolio.pages.dev · github.com/rahulrawat20022002 · linkedin.com/in/rahulrawat2r

Immatrikuliert bis April 2027 · Sofort verfügbar · Studentenvisum mit Arbeitserlaubnis

---

## PROFIL

Masterstudent der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim und praktischer Erfahrung im Aufbau von ML Pipelines fuer tabulare und Bilddaten sowie im belastbaren Vergleich moderner Verfahren gegen klassische Datenanalyse. Ich habe in meiner Bachelorarbeit sechs Klassifikatoren gegeneinander mit **10 facher** Kreuzvalidierung verglichen und in eigenen Projekten End to End Pipelines von Rohdaten bis zum produktionsreifen Modell gebaut. Sicher in Python, scikit learn, CatBoost, Pandas und in der Validierung und Dokumentation von Modellergebnissen fuer produktionsnahe Anwendungen.

## FÄHIGKEITEN

|                                 |                                                                                |
|---------------------------------|--------------------------------------------------------------------------------|
| <b>KI und Agenten</b>           | LangGraph, RAG, LLM as Judge, Prompt Engineering, Ollama, spaCy, BM25          |
| <b>Daten und ML</b>             | Python, SQL, PySpark, scikit learn, CatBoost, XGBoost, LightGBM, Prophet, MICE |
| <b>Cloud und Orchestrierung</b> | GCP, BigQuery, Cloud Run, AWS, Docker, Apache Airflow, dbt, Git                |
| <b>Dashboards</b>               | Tableau, Looker Studio, Streamlit, Power BI                                    |
| <b>Web</b>                      | React, module federation, Playwright, HTML5, CSS3                              |

---

## BERUFSERFAHRUNG

### eRay GmbH

Data Scientist · Heidelberg · Okt 2025 bis Mrz 2026

- In einer **6 monatigen** Zusammenarbeit zwischen eRay GmbH und SRH Hochschule Heidelberg zur Prognose der Seewasserqualität über **4 Ziel** Indikatoren Chlorophyll a, Trübung, pH und gelösten Sauerstoff wurde eine end to end rekursive Zeitreihen Pipeline über einen **40 Feature** Raum mit einem Ziel Lag Set lag\_1h, lag\_24h, lag\_3d, lag\_7d, lag\_roll\_mean\_24h und lag\_roll\_std\_24h aufgebaut.
- Es wurden **6 Kandidaten** direkt verglichen Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet mit strikten Tree Einschränkungen max\_depth 4 und learning\_rate **0.05**, die Entscheidung fiel auf CatBoost MultiQuantile bei alpha **0.05**, **0.5** und **0.85**, was asymmetrische **80 Prozent** Vorhersageintervalle lieferte, die den 0 Boden umarmen und die oberen **15 Prozent** der Sommer Ghost Spikes abschneiden.
- Die September Evaluation wurde belastbar gemacht mit einem **3 Pass** Outlier System pH verengt von **0 bis 14** auf **7.0 bis 9.0**, Oct und Nov Caps von **15.0** bei Chlorophyll a und **50.0** bei Trübung, ein rollender z-score bei  $z > 2.5$  über **48 Stunden**, und 5 spärliche Sensoren plus 3 zeitgleiche Proxies phycocyanin\_abs, phycocyanin\_abs\_comp und toc wurden ausgeschlossen, was die ehrliche R quadrat Aufteilung von **0.86** bei gelöstem Sauerstoff und **0.81** bei pH offenlegte.

**Technologies:** Python, CatBoost, Prophet, scikit learn, MICE

---

## AUSBILDUNG

### M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9 · Heidelberg · Apr 2025 bis heute

### Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10 · Greater Noida, India · 2019 to 2023

## PERSÖNLICHE PROJEKTE

---

### Echtzeit Flugverfolgungs Pipeline

2025

- Für ein Data Engineering Modul an der SRH Heidelberg, das eine Echtzeitsicht auf Live Flugzeuge über Deutschland benötigte, mit dem Auftrag die Sammel und Anreicherungsschicht zu bauen, wurden Python Collectors aufgesetzt, die die OpenSky Network API alle **30 Sekunden** abfragen, sowie PySpark Cleaning auf Google Cloud, das gegen Flughafen, Flugzeug und Wetterdaten aus vier Quellen joint, was eine saubere Join Tabelle mit über **128 tausend** Datensätzen ergab.
- Da Rohdaten der Collectors nicht direkt analysierbar waren und jedes Flugzeug ein nächstgelegenes Flughafen Label brauchte, mit dem Auftrag die Modellierungsschicht zu bauen, wurden die Daten mit dbt in analysebereite Tabellen geformt und der nächstgelegene Flughafen mit PySpark berechnet, was konsistente Labels über den gesamten historischen Zeitraum lieferte.
- Da manuelle Reruns das Echtzeit Versprechen brechen würden, mit dem Auftrag die Aktualisierung zu automatisieren, wurde das Gesamtsystem mit Apache Airflow auf GCS Speicher und Dataproc Compute so orchestriert, dass sich Batch und Echtzeit Schichten alle **15 Minuten** unbeaufsichtigt aktualisieren.

**Technologies:** Python, PySpark, BigQuery, dbt, Apache Airflow, GCP Dataproc und GCS, Tableau mit TabPy

## FORSCHUNG UND ABSCHLUSSARBEIT

---

### Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE style paper · Greater Noida, India · 2022 to 2023

- Für eine Bachelorarbeit zur Diabetesvorhersage auf einem kleinen klinischen Datensatz von **768 Patientinnen** und Patienten, mit dem Auftrag einen belastbaren Modellvergleich zu liefern, den die Prüfer nachprüfen können, wurde eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren, **10 facher** Kreuzvalidierung und pro Modell erstellten Konfusionsmatrizen aufgebaut, was einen Modellvergleich ergab, der in der Verteidigung standhielt.
- Nach dem Erkennen biologisch unmöglicher Nullwerte in den Quelldaten, die die Originalautoren übersehen hatten, mit dem Auftrag die Datenintegrität vor jedem Modelltraining wiederherzustellen, wurde eine IQR basierte Ausreißerbehandlung und saubere Imputation angewandt, was den Datensatz von still fehlerhaft zu einer sauberen Trainingsgrundlage für jedes nachgelagerte Modell brachte.
- Bei einer 65 zu **35 Klassenungleichgewicht** Verteilung, die Genauigkeit zu einer trügerisch schönen Leitmetrik gemacht hätte, mit dem Auftrag eine Bewertung zu wählen, die Fehler in der Minderheitsklasse nicht verdeckt, wurde die Leitmetrik von Genauigkeit auf ROC AUC umgestellt, was die realen Fehlermuster offenlegte, die die Genauigkeitszahl maskiert hatte und der Arbeit einen ehrlichen Leistungsvergleich gab.
- Da die Ergebnisse in der Substanz veröffentlichungsreif und nicht nur abgabefähig sein sollten, mit dem Auftrag sie formal aufzuschreiben, wurde ein IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie verfasst, das der Betreuer als in der Substanz veröffentlichungsreif akzeptierte.

**Technologies:** Python, scikit learn, Pandas, Seaborn

## ZERTIFIKATE

---

- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- SAS Certified Specialist: Visual Business Analytics Using SAS Viya, ausgestellt im Mai 2025.
- Google Data Analytics: Foundations, Data, Data, Everywhere, ausgestellt im April 2025 auf Coursera.

## AUSZEICHNUNGEN

---

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

## SPRACHEN

---

**Englisch:** Fließend, schriftlich und mündlich

**Deutsch:** B1, laufend