

Rahul Rawat

Masterstudent Data Science and Analytics | ML Pipelines fuer Produktionsdaten | Python + scikit learn + CatBoost

Mannheim, Deutschland · 015563603340 · rahulrawat2r@gmail.com

rah-portfolio.pages.dev · github.com/rahulrawat20022002 · linkedin.com/in/rahulrawat2r

Immatrikuliert bis April 2027 · Sofort verfügbar · Studentenvisum mit Arbeitserlaubnis

PROFIL

Masterstudent der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim und praktischer Erfahrung im Aufbau von ML Pipelines fuer tabulare und Bilddaten sowie im belastbaren Vergleich moderner Verfahren gegen klassische Datenanalyse. Ich habe in meiner Bachelorarbeit sechs Klassifikatoren gegeneinander mit **10 facher** Kreuzvalidierung verglichen und in eigenen Projekten End to End Pipelines von Rohdaten bis zum produktionsreifen Modell gebaut. Sicher in Python, scikit learn, CatBoost, Pandas und in der Validierung und Dokumentation von Modellergebnissen fuer produktionsnahe Anwendungen.

FÄHIGKEITEN

KI und Agenten	LangGraph, RAG, LLM as Judge, Prompt Engineering, Ollama, spaCy, BM25
Daten und ML	Python, SQL, PySpark, scikit learn, CatBoost, XGBoost, LightGBM, Prophet, MICE
Cloud und Orchestrierung	GCP, BigQuery, Cloud Run, AWS, Docker, Apache Airflow, dbt, Git
Dashboards	Tableau, Looker Studio, Streamlit, Power BI
Web	React, module federation, Playwright, HTML5, CSS3

BERUFSERFAHRUNG

eRay GmbH

Data Scientist · Heidelberg · Okt 2025 bis Mrz 2026

- In einer **6 monatigen** Zusammenarbeit zwischen eRay GmbH und SRH Hochschule Heidelberg zur Prognose der Seewasserqualität über **4 Ziel** Indikatoren Chlorophyll a, Trübung, pH und gelösten Sauerstoff wurde eine end to end rekursive Zeitreihen Pipeline über einen **40 Feature** Raum mit einem Ziel Lag Set lag_1h, lag_24h, lag_3d, lag_7d, lag_roll_mean_24h und lag_roll_std_24h aufgebaut.
- Es wurden **6 Kandidaten** direkt verglichen Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet mit strikten Tree Einschränkungen max_depth 4 und learning_rate **0.05**, die Entscheidung fiel auf CatBoost MultiQuantile bei alpha **0.05**, **0.5** und **0.85**, was asymmetrische **80 Prozent** Vorhersageintervalle lieferte, die den 0 Boden umarmen und die oberen **15 Prozent** der Sommer Ghost Spikes abschneiden.

Technologies: Python, CatBoost, Prophet, scikit learn, MICE

SS Engineers and Contractors

Junior Associate Software Developer · India · Aug 2023 bis Aug 2024

- Da SS Engineers and Contractors interne Data Dashboards, Analytics Plattformen und Mitarbeiter Portale betreibt, die unternehmensweit genutzt werden, mit dem Auftrag die Frontend Features zu bauen und zu pflegen, auf die die Teams im Alltag angewiesen sind, wurden React UI Komponenten in allen drei internen Produkten beigetragen, die während des gesamten Jahres in der Rolle im täglichen Einsatz der internen Teams blieben.

Technologies: React, module federation, Playwright, AngularJS, HTML5, CSS3

SS Engineers and Contractors

Front End Developer Intern · India · Feb 2023 bis Juli 2023

- Während eines sechsmonatigen Praktikums bei SS Engineers and Contractors, mit dem Auftrag die Codebasis kennenzulernen und dann unter Senior Review kleinere UI Arbeiten in den internen Data Dashboards und Mitarbeiter Portalen zu übernehmen, wurde eng mit Senior Entwicklern durch die Codebasis gegangen und anschließend wurden fokussierte UI Komponenten wie Charts, Filter und Profilseiten geliefert, jede iterativ auf Basis von Code Review Feedback verbessert bis sie freigegeben war.

Technologies: React, HTML5, CSS3, Git, code review workflow

AUSBILDUNG

M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9 · Heidelberg · Apr 2025 bis heute

Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10 · Greater Noida, India · 2019 to 2023

PERSÖNLICHE PROJEKTE

Echtzeit Flugverfolgungs Pipeline

2025

- Für ein Data Engineering Modul an der SRH Heidelberg, das eine Echtzeitsicht auf Live Flugzeuge über Deutschland benötigte, mit dem Auftrag die Sammel und Anreicherungsschicht zu bauen, wurden Python Collectors aufgesetzt, die die OpenSky Network API alle **30 Sekunden** abfragen, sowie PySpark Cleaning auf Google Cloud, das gegen Flughafen, Flugzeug und Wetterdaten aus vier Quellen joint, was eine saubere Join Tabelle mit über **128 tausend** Datensätzen ergab.
- Da Rohdaten der Collectors nicht direkt analysierbar waren und jedes Flugzeug ein nächstgelegenes Flughafen Label brauchte, mit dem Auftrag die Modellierungsschicht zu bauen, wurden die Daten mit dbt in analysebereite Tabellen geformt und der nächstgelegene Flughafen mit PySpark berechnet, was konsistente Labels über den gesamten historischen Zeitraum lieferte.

Technologies: Python, PySpark, BigQuery, dbt, Apache Airflow, GCP Dataproc und GCS, Tableau mit TabPy

FORSCHUNG UND ABSCHLUSSARBEIT

Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE style paper · Greater Noida, India · 2022 to 2023

- Für eine Bachelorarbeit zur Diabetesvorhersage auf einem kleinen klinischen Datensatz von **768 Patientinnen** und Patienten, mit dem Auftrag einen belastbaren Modellvergleich zu liefern, den die Prüfer nachprüfen können, wurde eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren, **10 facher** Kreuzvalidierung und pro Modell erstellten Konfusionsmatrizen aufgebaut, was einen Modellvergleich ergab, der in der Verteidigung standhielt.
- Nach dem Erkennen biologisch unmöglicher Nullwerte in den Quelldaten, die die Originalautoren übersehen hatten, mit dem Auftrag die Datenintegrität vor jedem Modelltraining wiederherzustellen, wurde eine IQR basierte Ausreißerbehandlung und saubere Imputation angewandt, was den Datensatz von still fehlerhaft zu einer sauberen Trainingsgrundlage für jedes nachgelagerte Modell brachte.

Technologies: Python, scikit learn, Pandas, Seaborn

ZERTIFIKATE

- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.

AUSZEICHNUNGEN

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

SPRACHEN

Englisch: Fließend, schriftlich und mündlich

Deutsch: B1, laufend