

Rahul Rawat

Masterstudent Data Science and Analytics | Loss Design und Evaluation bei Klassenungleichgewicht
| Python + scikit learn + CatBoost

Mannheim, Deutschland · 015563603340 · rahulrawat2r@gmail.com

rah-portfolio.pages.dev · github.com/rahulrawat20022002 · linkedin.com/in/rahulrawat2r

Immatrikuliert bis April 2027 · Sofort verfügbar · Studentenvisum mit Arbeitserlaubnis

PROFIL

Masterstudent der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim und praktischer Erfahrung im kritischen Vergleich von Modellierungsansätzen und Metriken unter starkem Klassenungleichgewicht. Ich habe in meiner Bachelorarbeit sechs Klassifikatoren verglichen und bei einer 65 zu **35 Klassen**ungleichgewicht Verteilung die Leitmetrik bewusst von Genauigkeit auf ROC AUC umgestellt, und in CreditIQ eine SHAP getriebene Subgruppenanalyse genutzt, um eine versteckte, durch die falsche Metrik verdeckte Verzerrung aufzudecken. Sicher in Python, Machine Learning Grundlagen und im Design und der kritischen Prüfung von Evaluationsmetriken.

FÄHIGKEITEN

KI und Agenten	LangGraph, RAG, LLM as Judge, Prompt Engineering, Ollama, spaCy, BM25
Daten und ML	Python, SQL, PySpark, scikit learn, CatBoost, XGBoost, LightGBM, Prophet, MICE
Cloud und Orchestrierung	GCP, BigQuery, Cloud Run, AWS, Docker, Apache Airflow, dbt, Git
Dashboards	Tableau, Looker Studio, Streamlit, Power BI
Web	React, module federation, Playwright, HTML5, CSS3

BERUFSERFAHRUNG

eRay GmbH

Data Scientist · Heidelberg · Okt 2025 bis Mrz 2026

- In einer **6 monatigen** Zusammenarbeit zwischen eRay GmbH und SRH Hochschule Heidelberg zur Prognose der Seewasserqualität über **4 Ziel** Indikatoren Chlorophyll a, Trübung, pH und gelösten Sauerstoff wurde eine end to end rekursive Zeitreihen Pipeline über einen **40 Feature** Raum mit einem Ziel Lag Set lag_1h, lag_24h, lag_3d, lag_7d, lag_roll_mean_24h und lag_roll_std_24h aufgebaut.
- Es wurden **6 Kandidaten** direkt verglichen Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet mit strikten Tree Einschränkungen max_depth 4 und learning_rate **0.05**, die Entscheidung fiel auf CatBoost MultiQuantile bei alpha **0.05**, **0.5** und **0.85**, was asymmetrische **80 Prozent** Vorhersageintervalle lieferte, die den 0 Boden umarmen und die oberen **15 Prozent** der Sommer Ghost Spikes abschneiden.
- Die September Evaluation wurde belastbar gemacht mit einem **3 Pass** Outlier System pH verengt von **0 bis 14** auf **7.0 bis 9.0**, Oct und Nov Caps von **15.0** bei Chlorophyll a und **50.0** bei Trübung, ein rollender z-score bei $z > 2.5$ über **48 Stunden**, und 5 spärliche Sensoren plus 3 zeitgleiche Proxies phycocyanin_abs, phycocyanin_abs_comp und toc wurden ausgeschlossen, was die ehrliche R quadrat Aufteilung von **0.86** bei gelöstem Sauerstoff und **0.81** bei pH offenlegte.

Technologies: Python, CatBoost, Prophet, scikit learn, MICE

AUSBILDUNG

M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9 · Heidelberg · Apr 2025 bis heute

Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10 · Greater Noida, India · 2019 to 2023

PERSÖNLICHE PROJEKTE

Multi Agent RAG mit LLM as Judge und mehrsprachiger EN und DE Unterstützung

2025

- Für ein rein englisches Hybrid RAG Policy Analysesystem mit BM25 und dichter Vektorsuche über einen **14 Dokumente** Policy Korpus, das deutschsprachige Nutzer nicht bedienen konnte, mit dem Auftrag mehrsprachige Unterstützung ohne Korpus Duplizierung hinzuzufügen, wurden Embeddings und Retrieval auf einen paraphrase multilingual MiniLM L12 v2 gemeinsamen Vektorraum migriert, sodass eine deutsche Anfrage englische Quellen abrufen und end to end auf Deutsch beantwortet wird.
- Da jeder Agent im Graph erneut Spracherkennung ausführte und inkonsistente Ausgabesprachen produzierte, mit dem Auftrag eine zentrale Wahrheitsquelle zu schaffen, wurde ein LanguageAgent gebaut, der geseedete Spracherkennung mit einem Confidence Floor zentralisiert, die Ausgabesprache Direktive an jeden nachgelagerten Agent weiterreicht und Preprocessing an sprachpassende spaCy Pipelines mit einem leeren Multilingual Fallback routet und die Sprache pro Chunk protokolliert, sodass Retrieval und Evaluation nach Sprache geschnitten werden können.

Technologies: Python, LangGraph Multi Agent, Ollama mit Mistral 7B und Qwen2.5 14B, Pinecone, paraphrase multilingual MiniLM L12 v2, spaCy, BM25

FORSCHUNG UND ABSCHLUSSARBEIT

Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE style paper · Greater Noida, India · 2022 to 2023

- Für eine Bachelorarbeit zur Diabetesvorhersage auf einem kleinen klinischen Datensatz von **768 Patientinnen** und Patienten, mit dem Auftrag einen belastbaren Modellvergleich zu liefern, den die Prüfer nachprüfen können, wurde eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren, **10 facher** Kreuzvalidierung und pro Modell erstellten Konfusionsmatrizen aufgebaut, was einen Modellvergleich ergab, der in der Verteidigung standhielt.
- Nach dem Erkennen biologisch unmöglicher Nullwerte in den Quelldaten, die die Originalautoren übersehen hatten, mit dem Auftrag die Datenintegrität vor jedem Modelltraining wiederherzustellen, wurde eine IQR basierte Ausreißerbehandlung und saubere Imputation angewandt, was den Datensatz von still fehlerhaft zu einer sauberen Trainingsgrundlage für jedes nachgelagerte Modell brachte.
- Bei einer 65 zu **35 Klassenungleichgewicht** Verteilung, die Genauigkeit zu einer trügerisch schönen Leitmetrik gemacht hätte, mit dem Auftrag eine Bewertung zu wählen, die Fehler in der Minderheitsklasse nicht verdeckt, wurde die Leitmetrik von Genauigkeit auf ROC AUC umgestellt, was die realen Fehlermuster offenlegte, die die Genauigkeitszahl maskiert hatte und der Arbeit einen ehrlichen Leistungsvergleich gab.
- Da die Ergebnisse in der Substanz veröffentlichungsreif und nicht nur abgabefähig sein sollten, mit dem Auftrag sie formal aufzuschreiben, wurde ein IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie verfasst, das der Betreuer als in der Substanz veröffentlichungsreif akzeptierte.

Technologies: Python, scikit learn, Pandas, Seaborn

ZERTIFIKATE

- NVIDIA: Building LLM Applications With Prompt Engineering, ausgestellt im November 2025.
- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- Google Data Analytics: Foundations, Data, Data, Everywhere, ausgestellt im April 2025 auf Coursera.

AUSZEICHNUNGEN

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

SPRACHEN

Englisch: Fließend, schriftlich und mündlich

Deutsch: B1, laufend