

Rahul Rawat

Masterarbeit im Bereich Process Mining

P E R S Ö N L I C H E D A T E N

Adresse	C2 16, 68159 Mannheim, Deutschland
Telefon	015563603340
E-Mail	rahulrawat2r@gmail.com
LinkedIn	linkedin.com/in/rahulrawat2r
GitHub	github.com/rahulrawat20022002
Portfolio	rah-portfolio.pages.dev
Geburtsdatum	20 February 2002
Nationalität	Indisch, Studentenvisum mit gültiger Arbeitserlaubnis
Verfügbarkeit	Werkstudent 20 Stunden pro Woche sofort, Vollzeit ab April 2027

P R O F I L

Masterstudent der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim und praktischer Erfahrung im Aufbau end to end Datenpipelines, Machine Learning auf Prozessdaten und BI Reporting. Ich habe eine vollstaendig automatisierte Bronze Silver Gold Medallion Pipeline in BigQuery mit einem leakage freien BigQuery ML Klassifikator und fuenfseitigem Looker Studio Dashboard umgesetzt, eine Echtzeit Cloud Pipeline mit PySpark, dbt und Apache Airflow ueber mehr als 128 tausend Datensatze betrieben und ein interaktives Tableau Dashboard mit dynamischen Set Actions und parametergesteuerten Analytiken ausgeliefert. Sicher in Python, SQL und mit analytischem und konzeptionellem Blick fuer betriebliche Prozessdaten, bin ich die richtige Verstaerkung fuer die Masterarbeit im Process Mining bei ROSEN in Lingen.

B E R U F S E R F A H R U N G

Okt 2025 bis Mrz 2026
Heidelberg

eRay GmbH
Data Scientist

- Im Rahmen einer sechsmonatigen Zusammenarbeit zwischen eRay GmbH und SRH Hochschule Heidelberg zur Prognose der Wasserqualität eines deutschen Sees, mit dem Auftrag vier Indikatoren über rollende Horizonte zu prognostizieren, wurde eine end to end rekursive Zeitreihen Pipeline für Chlorophyll a, Trübung, pH Wert und gelösten Sauerstoff aufgebaut, als produktionsreifes Modul geliefert, das der Kunde bei jeder neuen Sensordatenlieferung erneut ausführen kann.
- Angesichts unklarer Modellwahl für die Prognoseaufgabe und der Notwendigkeit, Unsicherheit gegenüber nichttechnischen Stakeholdern verständlich zu machen, wurden sechs Kandidaten direkt verglichen, Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet, und die Entscheidung fiel auf CatBoost Multi Quantil Regression, die asymmetrische 80 Prozent Vorhersageintervalle lieferte und dem Kunden Entscheidungsunterstützung unter Unsicherheit ermöglichte.
- Aus der Sorge, dass naive Zeitreihen Splits die Genauigkeit verzerren würden, mit dem Auftrag die Evaluation belastbar zu machen, wurden strenge Anti Leakage Regeln in der gesamten Pipeline erzwungen, was die ehrliche Erkenntnis offenlegte, dass pH Wert und gelöster Sauerstoff physikalisch vorhersagbar sind, während Chlorophyll a und Trübung ohne optische Live Sensorik nicht seriös prognostizierbar sind.
- Bei fehlenden Winter Messwerten und baumbasierten Modellen, die während der rekursiven Vorhersage flach wurden, mit dem Ziel realistische saisonale Muster in den nachgelagerten Prognosen zu erhalten, wurden fehlende Werte mit MICE Imputation rekonstruiert und ein synthetischer Winter Decay Prognose Rahmen entwickelt, was glaubwürdiges Winterverhalten wiederherstellte, ohne Verzerrung in das Trainingsfenster einzubringen.
- Um zu verhindern, dass fehlerhafte Daten sich rekursiv durch den Forecaster fortpflanzen, mit dem Auftrag die Ausführungsschleife zu härten, wurde die Pipeline mit einem Orchestrator mit Gate Checks sowie Geschwindigkeits und ökologischen Grenzen umschlossen, sodass eine fehlgeschlagene Imputation nun den Lauf stoppt, statt Wochen nachgelagerter Vorhersagen zu beschädigen.

Technologies: Python, CatBoost, Prophet, scikit learn, MICE

Aug 2023 bis Aug
2024
India

SS Engineers and Contractors

Junior Associate Software Developer

- Da SS Engineers and Contractors interne Data Dashboards, Analytics Plattformen und Mitarbeiter Portale betreibt, die unternehmensweit genutzt werden, mit dem Auftrag die Frontend Features zu bauen und zu pflegen, auf die die Teams im Alltag angewiesen sind, wurden React UI Komponenten in allen drei internen Produkten beigetragen, die während des gesamten Jahres in der Rolle im täglichen Einsatz der internen Teams blieben.
- Bei einem Kunden, dessen Legacy AngularJS Anwendung in einem bestehenden Module Federation Setup neben neueren React Micro Frontends laufen sollte, mit dem Auftrag die Screens des Kunden zu portieren ohne das laufende Produkt zu brechen, wurden rund 8 Routen von AngularJS auf React innerhalb der Module Federation Shell portiert, ausgeliefert über 4 Monate in schrittweisen Releases und ohne Produktionsausfälle während des Rollouts eingespielt.

Technologies: *React, module federation, Playwright, AngularJS, HTML5, CSS3*

Feb 2023 bis Aug
2023
India

SS Engineers and Contractors

Front End Developer Intern

- Während eines sechsmonatigen Praktikums bei SS Engineers and Contractors, mit dem Auftrag die Codebasis kennenzulernen und dann unter Senior Review kleinere UI Arbeiten in den internen Data Dashboards und Mitarbeiter Portalen zu übernehmen, wurde eng mit Senior Entwicklern durch die Codebasis gegangen und anschließend wurden fokussierte UI Komponenten wie Charts, Filter und Profilseiten geliefert, jede iterativ auf Basis von Code Review Feedback verbessert bis sie freigegeben war.

Technologies: *React, HTML5, CSS3, Git, code review workflow*

P E R S Ö N L I C H E P R O J E K T E

2025

Movie Analytics und ML Pipeline auf GCP

- Für ein persönliches Cloud Data Projekt zu Movie Analytics, das unbeaufsichtigt auf GCP laufen sollte, mit dem Auftrag die Ingestion und Verarbeitungsschicht zu bauen, wurde eine end to end Batch Pipeline aufgesetzt, die Filmdaten aus einer öffentlichen API in einen GCS Data Lake zieht und über eine Bronze Silver Gold Medallion Architektur in BigQuery auf Cloud Run verarbeitet, laufend über einen vollständig automatisierten Cloud Scheduler Trigger ohne manuellen Eingriff.
- Da die roh eingelesenen Daten für direkte Analytik ungeeignet waren, mit dem Auftrag die Silver Schicht zu härten, wurden Schema Enforcement, sicheres Type Casting, Deduplikation per Window Functions und Genre Normalisierung in ein relationales Modell angewandt, was in allen nachgelagerten Gold Tabellen saubere referenzielle Integrität lieferte.
- Da ein Klassifikator auf Post Release Signalen die Antwort geleakt hätte, mit dem Auftrag eine leakage freie Hit Vorhersage zu liefern, wurde ein BigQuery ML Klassifikator trainiert, der vor Kinostart vorhersagt ob ein Film ein Hit wird, indem Merkmale bewusst in zwei Tabellen aufgeteilt wurden so dass nur Pre Release Signale ins Modell fließen, und die Split Evaluation als leakage frei bestätigt wurde.

Technologies: *GCP BigQuery, Cloud Run, GCS, Cloud Scheduler, BigQuery ML, Python, SQL, Looker Studio*

A U S B I L D U N G

Apr 2025 bis
heute
Heidelberg

M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9

2019 to 2023
Greater Noida,
India

Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10

FORSCHUNG UND ABSCHLUSSARBEIT

2022 to 2023

Greater Noida,
India

Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE style paper

- Für eine Bachelorarbeit zur Diabetesvorhersage auf einem kleinen klinischen Datensatz von **768 Patientinnen** und Patienten, mit dem Auftrag einen belastbaren Modellvergleich zu liefern, den die Prüfer nachprüfen können, wurde eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren, 10 facher Kreuzvalidierung und pro Modell erstellten Konfusionsmatrizen aufgebaut, was einen Modellvergleich ergab, der in der Verteidigung standhielt.
- Nach dem Erkennen biologisch unmöglicher Nullwerte in den Quelldaten, die die Originalautoren übersehen hatten, mit dem Auftrag die Datenintegrität vor jedem Modelltraining wiederherzustellen, wurde eine IQR basierte Ausreißerbehandlung und saubere Imputation angewandt, was den Datensatz von still fehlerhaft zu einer sauberen Trainingsgrundlage für jedes nachgelagerte Modell brachte.
- Bei einer 65 zu 35 Klassenungleichgewicht Verteilung, die Genauigkeit zu einer trügerisch schönen Leitmetrik gemacht hätte, mit dem Auftrag eine Bewertung zu wählen, die Fehler in der Minderheitsklasse nicht verdeckt, wurde die Leitmetrik von Genauigkeit auf ROC AUC umgestellt, was die realen Fehlermuster offenlegte, die die Genauigkeitszahl maskiert hatte und der Arbeit einen ehrlichen Leistungsvergleich gab.
- Da die Ergebnisse in der Substanz veröffentlichungsreif und nicht nur abgabefähig sein sollten, mit dem Auftrag sie formal aufzuschreiben, wurde ein IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie verfasst, das der Betreuer als in der Substanz veröffentlichungsreif akzeptierte.

Technologies: *Python, scikit learn, Pandas, Seaborn*

ZERTIFIKATE

- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- SAS Certified Specialist: Visual Business Analytics Using SAS Viya, ausgestellt im Mai 2025.
- Google Data Analytics: Foundations, Data, Data, Everywhere, ausgestellt im April 2025 auf Coursera.

AUSZEICHNUNGEN

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

SPRACHEN

Englisch	Fließend, schriftlich und mündlich
Deutsch	B1 laufend Richtung B2
Hindi	Muttersprache