

Rahul Rawat

DATA ENGINEER UND ANALYST WERKSTUDENT

@ rahulrawat2r@gmail.com T 015563603340 in linkedin.com/in/rahulrawat2r
gh github.com/rahulrawat20022002 Loc Mannheim, Germany

PROFIL

Master Student der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim und praktischer Erfahrung im Aufbau produktionsreifer Datenpipelines. Ich habe eine PySpark und dbt gestützte Echtzeit Pipeline für über 128 tausend Flugpositionen auf Google Cloud betrieben, eine Bronze Silver Gold Medallion Architektur auf BigQuery mit BigQuery ML Klassifikator ausgeliefert und ein modulares Retrieval Augmented Generation System mit LangChain und Llama 3.1 8b via Groq umgesetzt. Sicher in Python und PySpark sowie mit einem Grundverständnis von Databricks nahen Plattformen und Large Language Models, bin ich die richtige Verstärkung für Data Engineering und Data Analysis auf der Palantir Foundry Plattform.

BERUFSERFAHRUNG

eRay GmbH

Okt 2025 bis Mrz 2026

Data Scientist

- Entwickelte eine end to end rekursive Zeitreihen Pipeline zur Prognose von Chlorophyll a, Trübung, pH Wert und gelöstem Sauerstoff für einen deutschen See, umgesetzt als sechsmonatige Zusammenarbeit mit der SRH Hochschule Heidelberg.
- Verglich sechs Modelle direkt, Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet, und nutzte CatBoost Multi Quantil Regression, um asymmetrische 80 Prozent Vorhersageintervalle für die Entscheidungsunterstützung unter Unsicherheit zu liefern.
- Erzwang strenge Anti Leakage Regeln in der gesamten Pipeline und legte die ehrliche Erkenntnis offen, dass pH Wert und gelöster Sauerstoff physikalisch vorhersagbar sind, während Chlorophyll a und Trübung ohne optische Live Sensorik nicht seriös prognostizierbar sind.
- Rekonstruierte fehlende Winter Messwerte mit MICE Imputation und entwickelte einen synthetischen Winter Decay Prognose Rahmen, damit baumbasierte Modelle während der rekursiven Vorhersage nicht flach werden.
- Umschloss die gesamte Pipeline mit einem Orchestrator, der Gate Checks sowie Geschwindigkeits und ökologische Grenzen prüft und bei fehlgeschlagener Imputation stoppt, statt schlechte Daten weiterfließen zu lassen.

AUSBILDUNG

M.Sc. Data Science and Analytics

Apr 2025 bis heute

SRH University of Applied Sciences Heidelberg

Bachelor of Technology in Computer Science

2019 bis 2023

GL Bajaj Institute of Technology and Management

PERSÖNLICHE PROJEKTE

Echtzeit Flugverfolgungs Pipeline

Python

PySpark

BigQuery

dbt

Apache Airflow

GCP Dataproc und GCS

Tableau mit TabPy

- Sammelte alle 30 Sekunden Live Flugpositionen von der OpenSky Network API und reicherte sie über vier Quellen aus Flughafen, Flugzeug und Wetterdaten an, messbar an einer sauberen Join Tabelle mit über 128 tausend Datensätzen, umgesetzt mit Python Collectors und PySpark Cleaning auf Google Cloud.
- Formte die Rohdaten mit dbt in analysebereite Tabellen und berechnete dabei den nächstgelegenen Flughafen jedes Flugzeugs, messbar an konsistenten Labels über den gesamten Zeitraum, gestützt auf PySpark für den Rechenaufwand und dbt für die Modellierungsschicht.
- Orchestrierte das Gesamtsystem mit Apache Airflow, so dass sich Batch und Echtzeit Schichten automatisch alle 15 Minuten aktualisieren, messbar an unbeaufsichtigten DAG Läufen auf GCS Speicher und Dataproc Compute.
- Visualisierte Erkenntnisse in einem Tableau Workbook mit Python Statistik über TabPy, messbar an der Erkenntnis, dass der Luftverkehr bei starkem Regen um Faktor 4,4 einbricht und sich um Drehkreuze wie Frankfurt und München bündelt, gestützt auf dbt Aggregate als Feed.

Movie Analytics und ML Pipeline auf GCP

GCP BigQuery

Cloud Run

GCS

Cloud Scheduler

BigQuery ML

Python

SQL

Looker Studio

- Baute eine end to end Batch Pipeline, die Filmdaten aus einer öffentlichen API in einen GCS Data Lake zieht und sie über eine Bronze Silver Gold Medallion Architektur in BigQuery verarbeitet, messbar an einem vollständig automatisierten Cloud Scheduler Trigger ohne manuellen Eingriff, umgesetzt mit Cloud Run als Compute Layer.
- Modellerte die Silver Schicht für verlässliche Analytik über Schema Enforcement, sicheres Type Casting, Deduplikation per Window Functions und Genre Normalisierung in ein relationales Modell, messbar an der referenziellen Integrität in allen Gold Tabellen.
- Trainierte einen BigQuery ML Klassifikator, der vor Kinostart vorhersagt, ob ein Film ein Hit wird, messbar an einer leakage freien Evaluation, indem Merkmale bewusst in zwei Tabellen aufgeteilt wurden, so dass nur Pre Release Signale ins Modell fließen.
- Baute Gold Aggregate und ein fünfseitiges Looker Studio Dashboard, das konkrete Business Fragen zu Genre ROI, Wachstum fremdsprachiger Filme und Release Saison Timing beantwortet, messbar gegen die ML Early Warning Sicht, und sicherte das System mit einem Least Privilege Service Account und Secret Manager ab.

Hybrider RAG Orchestrator mit agentischem Routing

Python

LangChain

Llama 3.1 8b via Groq

ChromaDB

HuggingFace MiniLM L6 v2

Streamlit

- Lieferte ein modulares Retrieval Augmented Generation System, das Nutzerintent in drei Ausführungspfade klassifiziert, lokale Wissensrecherche, externe Websuche oder direkte konversationelle Logik, messbar an sauberen end to end Antworten auf allen drei Pfaden, umgesetzt mit einem eigenen Decision Making Router über Llama 3.1 8b via Groq und LangChain.
- Baute ein persistentes semantisches Gedächtnis über PDF und Vektordaten auf, messbar an konsistenter Wiederfindung über Session Grenzen hinweg, gestützt auf ChromaDB mit lokaler Persistenz und HuggingFace MiniLM L6 v2 Embeddings.
- Erhielt Mehrturn Kontext für das LLM, messbar an kohärenten Nachfragen statt isolierten Einzelantworten, indem ein zustandsbehafteter MemoryAgent direkt in die Inference Pipeline eingebaut wurde.
- Lieferte das Gesamtsystem als Streamlit Interface aus, mit end to end Verantwortung, messbar an einem lauffähigen deployten Prototyp, gestützt auf Groq Inference und eine erweiterbare Routing Schicht.

FORSCHUNG UND ABSCHLUSSARBEIT

Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE Paper

- Entwickelte eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren auf einem klinischen Datensatz von 768 Patientinnen und Patienten, gestützt auf 10 fache Kreuzvalidierung und pro Modell erstellte Konfusionsmatrizen, damit der Modellvergleich prüfbar bleibt.
- Erkannte biologisch unmögliche Nullwerte, die die Originalautoren übersehen hatten, und entfernte diese über IQR basierte Ausreißerbehandlung und saubere Imputation, um die Datenintegrität vor jedem Modelltraining wiederherzustellen.
- Wählte ROC AUC statt Genauigkeit als Leitmetrik für einen unausgebalancierten Datensatz mit 65 zu 35 Verteilung, um eine trügerisch schöne Genauigkeit zu vermeiden, die reale Fehler in der Minderheitsklasse verdeckt hätte.
- Verfasste die Ergebnisse als IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie, in Substanz veröffentlichungsreif.

ZERTIFIKATE

- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- NVIDIA: Building LLM Applications With Prompt Engineering, ausgestellt im November 2025.
- SAS Certified Specialist: Visual Business Analytics Using SAS Viya, ausgestellt im Mai 2025.

AUSZEICHNUNGEN

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

SPRACHEN

Englisch: fließend, professionell. **Deutsch:** B1, in Bearbeitung.