

Rahul Rawat

Werkstudent Data Science und Process Mining

PERSÖNLICHE DATEN

Adresse: C2 16, 68159 Mannheim, Deutschland

Telefon: 015563603340

E-Mail: rahulrawat2r@gmail.com

LinkedIn: linkedin.com/in/rahulrawat2r

GitHub: github.com/rahulrawat20022002

Portfolio: rah-portfolio.pages.dev

Geburtsdatum: 20 February 2002

Nationalität: Indisch, Studentenvisum mit gültiger Arbeitserlaubnis

Verfügbarkeit: Werkstudent 20 Stunden pro Woche sofort, Vollzeit ab April 2027

PROFIL

Masterstudent der Data Science and Analytics an der SRH Heidelberg mit Sitz in Mannheim und praktischer Erfahrung in Python basierter Datenanalyse, ML Pipelines und Cloud Orchestrierung auf realen Ereignis und Sensordaten. Bei eRay GmbH habe ich eine end to end rekursive Zeitreihen Pipeline ueber 40 Merkmale gebaut, die aus rohen Sensordaten mit Luecken und biologisch unmoeeglichen Werten eine bereinigte Modellierungseingabe erzeugt, und im Rahmen eines Data Engineering Moduls an der SRH eine Echtzeit Datenpipeline auf GCP mit PySpark, dbt und Airflow. Sicher in Python, SQL, PySpark, dbt, Airflow, BigQuery, scikit-learn, CatBoost, LangGraph, GCP und AWS.

FÄHIGKEITEN

Python, SQL, PySpark, BigQuery, Databricks, Delta Lake, Power BI, Tableau, Looker Studio, LangChain, LangGraph, Ollama, CatBoost, LightGBM, XGBoost, Prophet, MICE, scikit-learn, PyTorch, dbt, Apache Airflow, GCP, AWS, Docker, Git, React, Playwright

BERUFSERFAHRUNG

eRay GmbH

Data Scientist · Heidelberg · Okt 2025 bis Mrz 2026

- In einer **6 monatigen** Zusammenarbeit zwischen eRay GmbH und SRH Hochschule Heidelberg zur Prognose der Seewasserqualität über **4 Ziel** Indikatoren Chlorophyll a, Trübung, pH und gelösten Sauerstoff wurde eine end to end rekursive Zeitreihen Pipeline über einen **40 Feature** Raum mit einem Ziel Lag Set lag_1h, lag_24h, lag_3d, lag_7d, lag_roll_mean_24h und lag_roll_std_24h aufgebaut.
- Es wurden **6 Kandidaten** direkt verglichen Ridge, Gradient Boosting, LightGBM, XGBoost, CatBoost und Prophet mit strikten Tree Einschränkungen max_depth 4 und learning_rate **0.05**, die Entscheidung fiel auf CatBoost MultiQuantile bei alpha **0.05**, **0.5** und **0.85**, was asymmetrische **80 Prozent** Vorhersageintervalle lieferte, die den 0 Boden umarmen und die oberen **15 Prozent** der Sommer Ghost Spikes abschneiden.
- Die September Evaluation wurde belastbar gemacht mit einem **3 Pass** Outlier System pH verengt von **0 bis 14** auf **7.0 bis 9.0**, Oct und Nov Caps von **15.0** bei Chlorophyll a und **50.0** bei Trübung, ein rollender z-score bei $z > 2.5$ über **48 Stunden**, und 5 spärliche Sensoren plus 3 zeitgleiche Proxies phycocyanin_abs, phycocyanin_abs_comp und toc wurden ausgeschlossen, was die ehrliche R quadrat Aufteilung von **0.86** bei gelöstem Sauerstoff und **0.81** bei pH offenlegte.
- Oct und Nov Lücken wurden mit IterativeImputer MICE rekonstruiert, eine vollständige Memory Buffer Neuberechnung über alle 6 Lag Features durchgeführt, ein synthetisches Winter Canvas mit 4 Grad Celsius Boden und **0.4** Grad diurnaler Amplitude generiert und das Ganze in einen Orchestrator mit Gate Checks, ökologischen Clips gelöster Sauerstoff **4.0 bis 18.0** und pH **6.0 bis 9.0** und einem **0.003** pH pro Stunde Velocity Clamp eingebettet.

Technologies: Python, CatBoost, Prophet, scikit learn, MICE

SS Engineers and Contractors

Junior Associate Software Developer · India · Aug 2023 bis Aug 2024

- Da SS Engineers and Contractors interne Data Dashboards, Analytics Plattformen und Mitarbeiter Portale betreibt, die unternehmensweit genutzt werden, mit dem Auftrag die Frontend Features zu bauen und zu pflegen, auf die die Teams im Alltag angewiesen sind, wurden React UI Komponenten in allen drei internen Produkten beigetragen, die während des gesamten Jahres in der Rolle im täglichen Einsatz der internen Teams blieben.
- Bei einem Kunden, dessen Legacy AngularJS Anwendung in einem bestehenden Module Federation Setup neben neueren React Micro Frontends laufen sollte, mit dem Auftrag die Screens des Kunden zu portieren ohne das laufende Produkt zu brechen, wurden rund **8 Routen** von AngularJS auf React innerhalb der Module Federation Shell portiert, ausgeliefert über **4 Monate** in schrittweisen Releases und ohne Produktionsausfälle während des Rollouts eingespielt.

Technologies: React, module federation, Playwright, AngularJS, HTML5, CSS3

SS Engineers and Contractors

Front End Developer Intern · India · Feb 2023 bis Juli 2023

- Während eines sechsmonatigen Praktikums bei SS Engineers and Contractors, mit dem Auftrag die Codebasis kennenzulernen und dann unter Senior Review kleinere UI Arbeiten in den internen Data Dashboards und Mitarbeiter Portalen zu übernehmen, wurde eng mit Senior Entwicklern durch die Codebasis gegangen und anschließend wurden fokussierte UI Komponenten wie Charts, Filter und Profilseiten geliefert, jede iterativ auf Basis von Code Review Feedback verbessert bis sie freigegeben war.

Technologies: React, HTML5, CSS3, Git, code review workflow

AUSBILDUNG

M.Sc. Data Science and Analytics

SRH University of Applied Sciences Heidelberg, GPA 1.9 · Heidelberg · Apr 2025 bis heute

Bachelor of Technology in Computer Science

GL Bajaj Institute of Technology and Management, CGPA 7.3 of 10 · Greater Noida, India · 2019 to 2023

PERSÖNLICHE PROJEKTE

Echtzeit Flugverfolgungs Pipeline

2025

- Für ein Data Engineering Modul an der SRH Heidelberg, das eine Echtzeitsicht auf Live Flugzeuge über Deutschland benötigte, mit dem Auftrag die Sammel und Anreicherungsschicht zu bauen, wurden Python Collectors aufgesetzt, die die OpenSky Network API alle **30 Sekunden** abfragen, sowie PySpark Cleaning auf Google Cloud, das gegen Flughafen, Flugzeug und Wetterdaten aus vier Quellen joint, was eine saubere Join Tabelle mit über **128 tausend** Datensätzen ergab.
- Da Rohdaten der Collectors nicht direkt analysierbar waren und jedes Flugzeug ein nächstgelegenes Flughafen Label brauchte, mit dem Auftrag die Modellierungsschicht zu bauen, wurden die Daten mit dbt in analysebereite Tabellen geformt und der nächstgelegene Flughafen mit PySpark berechnet, was konsistente Labels über den gesamten historischen Zeitraum lieferte.
- Da manuelle Reruns das Echtzeit Versprechen brechen würden, mit dem Auftrag die Aktualisierung zu automatisieren, wurde das Gesamtsystem mit Apache Airflow auf GCS Speicher und Dataproc Compute so orchestriert, dass sich Batch und Echtzeit Schichten alle **15 Minuten** unbeaufsichtigt aktualisieren.

Technologies: Python, PySpark, BigQuery, dbt, Apache Airflow, GCP Dataproc und GCS, Tableau mit TabPy

FORSCHUNG UND ABSCHLUSSARBEIT

Bachelorarbeit: Diabetesvorhersage mit Machine Learning

GL Bajaj Institute of Technology and Management, IEEE style paper · Greater Noida, India · 2022 to 2023

- Für eine Bachelorarbeit zur Diabetesvorhersage auf einem kleinen klinischen Datensatz von **768 Patientinnen** und Patienten, mit dem Auftrag einen belastbaren Modellvergleich zu liefern, den die Prüfer nachprüfen können, wurde eine vollständige end to end Machine Learning Pipeline mit sechs Klassifikatoren, **10 facher** Kreuzvalidierung und pro Modell erstellten Konfusionsmatrizen aufgebaut, was einen Modellvergleich ergab, der in der Verteidigung standhielt.
- Nach dem Erkennen biologisch unmöglicher Nullwerte in den Quelldaten, die die Originalautoren übersehen hatten, mit dem Auftrag die Datenintegrität vor jedem Modelltraining wiederherzustellen, wurde eine IQR basierte Ausreißerbehandlung und saubere Imputation angewandt, was den Datensatz von still fehlerhaft zu einer sauberen Trainingsgrundlage für jedes nachgelagerte Modell brachte.
- Bei einer 65 zu **35 Klassen**ungleichgewicht Verteilung, die Genauigkeit zu einer trügerisch schönen Leitmetrik gemacht hätte, mit dem Auftrag eine Bewertung zu wählen, die Fehler in der Minderheitsklasse nicht verdeckt, wurde die Leitmetrik von Genauigkeit auf ROC AUC umgestellt, was die realen Fehlermuster offenlegte, die die Genauigkeitszahl maskiert hatte und der Arbeit einen ehrlichen Leistungsvergleich gab.
- Da die Ergebnisse in der Substanz veröffentlichungsreif und nicht nur abgabefähig sein sollten, mit dem Auftrag sie formal aufzuschreiben, wurde ein IEEE Paper mit einem ehrlichen Abschnitt zu Grenzen und Verbesserungsvorschlägen für eine Folgestudie verfasst, das der Betreuer als in der Substanz veröffentlichungsreif akzeptierte.

Technologies: *Python, scikit learn, Pandas, Seaborn*

ZERTIFIKATE

- NVIDIA: Building LLM Applications With Prompt Engineering, ausgestellt im November 2025.
- AWS Academy Graduate: AWS Academy Cloud Foundations, ausgestellt im Juli 2025.
- Google Data Analytics: Foundations, Data, Data, Everywhere, ausgestellt im April 2025 auf Coursera.

AUSZEICHNUNGEN

- USAII Global AI Hackathon 2026: Finalist auf Graduate Level, ausgezeichnet vom United States Artificial Intelligence Institute für Innovation, technische Kreativität und angewandte KI an realen Herausforderungen.

SPRACHEN

Englisch: Fließend, schriftlich und mündlich

Deutsch: B1 laufend Richtung B2

Hindi: Muttersprache